

Trabajo Práctico N°3

Manuel Hirsch

Padrón: 110221

mhirsch@fi.uba.ar

Índice

1. Introducción Teórica	2
2. Ejercicio: Aprendizaje de distribución en forma geométrica	2
2.1. Círculo unitario	2
2.2. Cuadrado	3
2.3. Triángulo	3
2.4. Anillo	3
2.5. Dos anillos concéntricos	3
2.6. Dos clusters gaussianos	3
2.7. Letra M	4
3. Ejercicio 2: Travelling Salesman Problem	4
3.1. $M/N = 1$	5
3.2. $M/N = 2$	5
3.3. $M/N = 3$	7
4. Ejercicio 3: Reducción de dimensionalidad y clustering	7

1. Introducción Teórica

Una red de Kohonen recibe entradas $\bar{x} \in \mathbb{R}^n$ y las mapea a una grilla 2D de neuronas. Cada neurona i tiene asociado un vector de pesos $\bar{w}_i \in \mathbb{R}^n$ del mismo tamaño que la entrada.

Neurona ganadora (BMU)

Dado un estímulo $\bar{x}$, la neurona ganadora i^* es aquella cuyos pesos son más cercanos a la entrada:

$$\|\bar{w}_{i^*} - \bar{x}\| \leq \|\bar{w}_i - \bar{x}\| \quad \forall i \quad (1)$$

Vecindad en la grilla

Cada neurona i tiene una posición $\bar{r}_i = (r_{i1}, r_{i2})$ en la grilla. La distancia entre dos neuronas i e i^* en la grilla se define como:

$$d_{(i, i^*)} = \|\bar{r}_i - \bar{r}_{i^*}\| \quad (2)$$

La función de vecindad gaussiana, que determina cuánto se actualiza cada neurona en función de su distancia a la ganadora, es:

$$V(i, i^*) = e^{-\frac{d_{(i, i^*)}^2}{\sigma^2}} \quad (3)$$

donde σ es el radio de vecindad, que decrece a lo largo del entrenamiento ($\sigma \approx \sigma_0 \cdot 0.99^t$ en la formulación discreta).

Actualización de pesos

En cada paso de entrenamiento se actualizan los pesos de todas las neuronas según:

$$\Delta w_{ij} = \eta (\bar{x}(s) - w_{ij}) V(i, i^*) \quad (4)$$

donde η es la tasa de aprendizaje y $\bar{x}(s)$ es la muestra presentada en el paso s . Las neuronas cercanas a la ganadora (alto V) se actualizan más, mientras que las lejanas apenas se modifican.

2. Ejercicio: Aprendizaje de distribución en forma geométrica

Se implementó una red de Kohonen de grilla 10×10 con 2 entradas. Los pesos se inicializan aleatoriamente en $[-1, 1]^2$ y se entrenan durante 10.000 iteraciones usando una función de vecindad gaussiana con radio σ decreciente. En cada figura se muestran snapshots del mapa en distintas iteraciones: los puntos grises son las muestras de entrenamiento, los nodos rojos son los pesos de las neuronas y las líneas azules conectan neuronas vecinas en la grilla.

2.1. Círculo unitario

En la figura 1 se puede observar cómo la grilla se despliega desde una distribución inicial desordenada hasta adaptarse a la forma circular, cubriendo el disco de manera uniforme y preservando la vecindad entre neuronas.




Figura 1: Evolución del mapa entrenado sobre el círculo unitario.

2.2. Cuadrado

En la figura 2 se puede observar que el cuadrado es la figura más compatible con la topología de una grilla rectangular: el mapa converge rápidamente sin cruces ni pliegues, cubriendo de forma uniforme toda la región.




Figura 2: Evolución del mapa entrenado sobre el cuadrado $[-1, 1]^2$.

2.3. Triángulo

En la figura 3 se puede observar que la red logra adaptarse a la forma triangular, aunque la incompatibilidad entre la grilla cuadrada y la geometría triangular genera cierta distorsión en las esquinas, donde algunas neuronas quedan comprimidas.




Figura 3: Evolución del mapa entrenado sobre el triángulo.

2.4. Anillo

En la figura 4 se puede observar que el anillo es topológicamente incompatible con una grilla plana: para cubrirlo, la grilla necesitaría cerrarse sobre sí misma. El resultado final muestra pliegues o cruces inevitables en algún punto del mapa.




Figura 4: Evolución del mapa entrenado sobre un anillo ($r \in [0,5, 1,0]$).

2.5. Dos anillos concéntricos

En la figura 5 se puede observar que la distribución, al tener dos regiones separadas por una zona vacía, genera tensión topológica en el mapa: la grilla se divide entre ambas regiones y se forman pliegues en la zona de transición.

2.6. Dos clusters gaussianos

En la figura 6 se puede observar que el mapa asigna grupos de neuronas a cada cluster, con la separación entre ambos claramente reflejada en la organización de la grilla.




Figura 5: Evolución del mapa entrenado sobre dos anillos concéntricos.




Figura 6: Evolución del mapa entrenado sobre dos clusters gaussianos.

2.7. Letra M

En la figura 7 se puede observar que la estructura ramificada de la letra M no puede representarse sin cruces con una grilla plana. El mapa logra adaptarse a los trazos principales, aunque aparecen pliegues en las zonas donde los segmentos se unen.




Figura 7: Evolución del mapa entrenado sobre la figura de la letra M.

3. Ejercicio 2: Travelling Salesman Problem

El *Traveling Salesman Problem* (TSP) consiste en encontrar el tour de mínima longitud que visite exactamente una vez cada una de las N ciudades y regrese al punto de partida. El problema es NP-hard, por lo que en la práctica se buscan soluciones aproximadas.

La diferencia clave respecto al ejercicio anterior es la topología de la red: en lugar de una grilla 2D, se usa un **anillo 1D** de M neuronas (con $M > N$). El orden de las neuronas en el anillo define directamente el orden de visita del tour. Las neuronas se inicializan en un pequeño círculo centrado en el centroide de las ciudades.

La distancia entre dos neuronas i y j en el anillo es circular:

$$d_{\text{ring}}(i, j) = \min(|i - j|, M - |i - j|) \quad (5)$$

lo que garantiza que la vecindad se envuelva al llegar al extremo del anillo.

En cada época se presentan todas las ciudades. Para cada ciudad $\bar{x}$, se encuentra la neurona ganadora i^* (la más cercana en espacio euclídeo) y se actualizan los pesos con la misma regla que en el ejercicio 1, pero usando d_{ring} en la función de vecindad gaussiana.

Se experimentó con distintos valores del factor $M/N \in \{1, 2, 3\}$. Tener más neuronas que ciudades permite una mejor cobertura del espacio pero aumenta el costo computacional. La calidad de la solución se evalúa con la longitud total del tour.

3.1. $M/N = 1$

Como primer intento se utilizó un factor $M/N = 1$, para ver si con una neurona por ciudad era suficiente. En la figura 8 se observa como la red aprende paulatinamente y se adapta a un recorrido que abarca cada una de las ciudades. Empieza como un círculo pequeño y alrededor de la epoca 49 ya se agranda, cubriendo el terreno de todas las ciudades.

Al finalizar el entrenamiento, como se observa en la figura 9, la red logra trazar un recorrido cerrado que cubre la región de las ciudades. Sin embargo, con $M/N = 1$ el anillo no tiene suficiente resolución para adaptarse a todas ellas: el camino formado por los pesos de las neuronas no logra exactamente por todas las ciudades. Se aumentó el número de épocas de entrenamiento, pero aun así el resultado no mejoró significativamente. Se concluye que un factor $M/N = 1$ es insuficiente para obtener una solución de calidad.




Figura 8: Evolución del anillo entrenado sobre el conjunto de ciudades.




Figura 9: Resolución de la red para $M/N = 1$.

3.2. $M/N = 2$

Para la segunda prueba se incrementó la cantidad de neuronas por ciudad al doble. En la figura 10 se puede observar el proceso de aprendizaje y en la figura 11 el camino final trazado por las neuronas.

Se puede observar como en este caso las neuronas logran pasar directamente por casi todas las ciudades. Vale la pena notar que los pliegues extra que se requieren para lograr esto hacen que el camino sea más largo.




Figura 10: Evolución del anillo entrenado sobre el conjunto de ciudades.




Figura 11: Resolución de la red para $M/N = 2$.

3.3. $M/N = 3$

Para el último caso, se aumentó una vez más la relación neurona/ciudad. Las figuras 12 y 13 muestran el resultado. Se observa una leve mejora respecto del caso anterior. Ahora si todas las ciudades son cubiertas por el recorrido, haciendo el camino sea un poco más largo.




Figura 12: Evolución del anillo entrenado sobre el conjunto de ciudades.




Figura 13: Resolución de la red para $M/N = 3$.

Entonces se puede concluir, que a fines prácticos, la red de Kohonen hace un buen trabajo para encontrar una aproximación del camino ideal. El factor $M/N = 2$ hizo un trabajo lo suficientemente bueno como para poder apreciar el orden de visita de las ciudades.

4. Ejercicio 3: Reducción de dimensionalidad y clustering

Los datos consisten en 500 muestras de una variable de 100 dimensiones. El objetivo es reducir la dimensionalidad y detectar la presencia de clusters.

La reducción de dimensionalidad surge de forma natural al entrenar una SOM sobre datos de alta dimensión: cada neurona de la grilla 2D aprende a representar una región del espacio de 100 dimensiones, de modo que cualquier muestra puede mapearse a la posición 2D de su BMU. Así, el entrenamiento transforma implícitamente cada vector de $\mathbb{R}^{100}$ en una coordenada (i, j) de la grilla, pasando de 100 dimensiones a 2 sin necesidad de ningún paso adicional.

Para detectar clusters se utiliza la **matriz U** (*Unified Distance Matrix*): para cada neurona se calcula la distancia promedio a sus vecinas en la grilla. Zonas con distancias bajas (neuronas similares entre sí) corresponden a regiones densas del espacio de entrada, mientras que zonas con distancias altas indican fronteras entre clusters.

En la figura 14 se observa como los colores oscuros representan las zonas densas, indicando la presencia de clusters. Por otro lado, las zonas claras evidencian alta distancia entre neuronas vecinas, lo cual significa separación de clusters. Se pueden identificar 5 clusters fácilmente.




Figura 14: Matriz U con código de colores para poder identificar clusters.

5. Conclusión

A lo largo del trabajo se exploraron tres aplicaciones de las redes de Kohonen, evidenciando su versatilidad como herramienta de aprendizaje no supervisado.

En el primer ejercicio se comprobó la capacidad de la red para aprender distribuciones arbitrarias en $\mathbb{R}^2$ y preservar su topología. En figuras compatibles con la grilla (cuadrado, círculo, triángulo) el mapa converge sin distorsiones, mientras que en figuras topológicamente incompatibles (anillo, letra M) aparecen pliegues inevitables, lo cual es una consecuencia directa de la incompatibilidad entre la topología de la grilla y la del espacio de entrada.

En el segundo ejercicio se utilizó la red para aproximar el TSP. Se observó que el factor M/N es determinante: con $M/N = 1$ la resolución es insuficiente, mientras que con $M/N = 2$ la red ya logra un recorrido de calidad aceptable. Aumentar el factor a $M/N = 3$ ofrece una mejora marginal a costa de mayor longitud de camino, por lo que $M/N = 2$ resulta el mejor balance entre calidad y costo.

Finalmente, en el tercer ejercicio se utilizó la SOM para reducir la dimensionalidad de datos de 100 dimensiones a una representación 2D, y mediante la matriz U se identificaron 5 clusters en los datos. Esto ilustra cómo la red actúa simultáneamente como reductor de dimensionalidad y como herramienta de análisis exploratorio.